



FACULTY OF ENGINEERING AND BASIC SCIENCES

Project - Extracción, Transformación y carga

ACADEMIC PROGRAM: DATA ENGINEERING AND ARTIFICIAL INTELLIGENCE

Integrantes:

JUAN DAVID MEZA PENA - 2240129

SANTIAGO URIBE LONDOÑO - 2243533

ANDRES DAVID ZAMBRANO MCCORMICK - 2249266

Contexto del proyecto

Este análisis de proyecto “**Proportion of population with primary reliance on clean fuels and technologies**” “**Proporción de la población que depende principalmente de combustibles y tecnologías limpias**” es una problemática global que afecta a múltiples poblaciones en todo el mundo durante los años 2000-2023, la cual en diversos estudios de la OMS (Organización mundial de la salud), se amplía la causa de la exposición a contaminantes del aire en interiores, lo que provoca una amplia gama de efectos adversos para la salud. Siendo así un detonante de afecciones oculares, enfermedades respiratorias y cáncer en la sociedad debido al uso de combustibles y dispositivos tecnológicos altamente contaminantes en zonas rurales y países en desarrollo.

Evaluación de la Fuente de Datos

¿Por qué se eligió el dataset?

El dataset fue elegido debido a que es una fuente confiable e importante para el análisis de la problemática del indicador séptimo de los objetivos de desarrollo sostenible, proveniente de la organización mundial de la salud (OMS), estos datos son reales y están respaldados por autoridades oficiales, el CSV facilita el trabajo y se puede migrar a una base de datos relacional. La organización logra de las variables, indicadores o contenido se pueda hacer diversos comparativos y

manejarlo fácilmente en un Data Warehouse y una cosa muy importante es que el dataset tiene un potencial para expandirlo a futuro, es decir que se puede relacionar con múltiples datasets que contengan temas de salud, energía o desarrollo sostenible.

Objetivo general

En este proyecto se busca desarrollar un proceso de ETL básico para extraer, cargar, analizar, transformar y visualizar un dataset del ODS 7 (Indicador 7.1.2), utilizando una base de datos relacional como fuente principal del análisis, con el fin de poder identificar y/o estudiar patrones o tendencias sobre el acceso a combustibles y tecnologías limpias para cocinar.

Objetivos específicos

1. primeramente seleccionar un dataset alineado con ODS 7 explicando su relevancia para el problema
2. Cargar el archivo CSV del dataset en un base de datos relacional como raw dataset conservando su estructura original
3. Realizar un EDA (análisis exploratorio de datos) desde la base de datos identificando
 - pendiente
4. Aplicar procesos de limpieza y transformación (renombrado de columnas, corrección de tipos de datos, filtrado de variables y estandarización de valores, para generar un dataset transformado.
5. Almacenar el dataset transformado en la base de datos para su uso en análisis y visualización.
6. Construir un dashboard a partir del dataset transformado, orientados a responder preguntas clave del proyecto.
7. Documentar la arquitectura ETL, el modelo de datos y los resultados obtenidos en un reporte técnico en github.

Requisitos del proyecto

Requisitos funcionales

1. Importar un archivo CSV con el dataset seleccionado (mínimo 10.000 filas y 10 columnas)
2. Migrar el CSV a una base de datos relaciona
3. Guardar una versión raw del dataset en la base de datos
4. Ejecutar consultas desde la base de datos para realizar el EDA
5. Aplicar transformaciones al dataset para generar una versión limpia y analítica.
6. Guardar el dataset transformado en la base de datos.
7. Generar gráficos / dashboard usando únicamente datos consultados desde la base de datos.
8. Exportar resultados (gráficos, tablas, conclusiones) para incluirlos en el informe.
9. Mantener el proyecto versionado en GitHub con estructura clara y commits informativos.

Requisitos no funcionales

1. Reproducibilidad: el proceso ETL debe poder ejecutarse múltiples veces con resultados consistentes.
2. Integridad de datos: la migración debe conservar los registros sin pérdidas ni modificaciones no justificadas.
3. Organización del proyecto: estructura clara de carpetas y archivos (scripts, notebooks, SQL, documentación, etc.).
4. Legibilidad del código: código comprensible, con nombres adecuados y comentarios cuando sea necesario.

5. Documentación: inclusión de README, justificación del stack tecnológico e instrucciones de ejecución.
6. Control de versiones: uso correcto de Git, GitHub y archivo `.gitignore`.
7. Trazabilidad: diferenciación explícita entre dataset raw y dataset transformado.

Requisitos de el dataset

El dataset seleccionado debe cumplir con los siguientes criterios:

1. Estar alineado con al menos un ODS (ODS 7).
2. Contar con mínimo 10.000 filas.
3. Contar con mínimo 10 columnas.
4. Estar disponible en un formato procesable, preferiblemente CSV.
5. Incluir variables útiles para análisis temporal, geográfico y/o categórico.
6. Permitir justificar su disponibilidad, relevancia, estructura y calidad.

<https://www.who.int/data/gho/data/themes/air-pollution/household-air-pollution>

Requisitos de análisis (EDA y visualización)

El análisis debe incluir, como mínimo:

1. revisión de valores nulos,
2. revisión de tipos de datos,
3. descripción general de variables,
4. identificación de tendencias y diferencias relevantes,
5. visualizaciones que soporten los objetivos del proyecto.

Nota: todas las consultas de la información se harán directamente desde la base de datos no desde el archivo CSV.

Requisitos de arquitectura (según el proceso propuesto)

La arquitectura del proyecto seguirá el siguiente flujo:

1. CSV > Raw Dataset (Base de datos)
2. EDA desde la base de datos
3. Transformación y limpieza > Transformed Dataset (Base de datos)
4. Visualización / Dashboard (desde el dataset transformado).

Alcance de esta primera entrega

En esta primera entrega se desarrollará:

1. selección y justificación del dataset en relación con el ODS,
2. evaluación de la fuente de datos,
3. diseño de arquitectura ETL básica,
4. migración del CSV a base de datos,
5. EDA inicial,
6. transformaciones principales,
7. visualizaciones / dashboard.